

Statistinės duomenų analizės praktinės užduotys

2017

7. Dažnių lentelės. Atitinkami R pavyzdžiai

- (a) *Hipotezės apie polinominio skirstinio parametrų reikšmes tikrinimas.* (ČM III.5.1) Atliktas tyrimas, kurio tikslas - nustatyti, kokios spalvos automobiliai populiariausi. Atsitiktinai apklausus 200 potencialių pirkėjų, gauti rezultatai, kurie pateikiami lentelėje.

| Spalva | Raudona | Geltona | Mėlyna | Žalia | Ruda |
|--------|---------|---------|--------|-------|------|
| Dažnis | 39 | 65 | 46 | 37 | 13 |

Patikrinkite hipotezę, kad pirkėjai nevienodai vertina automobilių spalvas.

```
# Naudojame visur chi-squared (asimptotiniai reiks), bet jei norėtumėm tiksliai
# tai pabandome su Fisheriu (nors tai nėra būtina)
daznis <- c(39, 65, 46, 37, 13)

t <- chisq.test(daznis)
pv <- t$p.value
t
```

```
##
## Chi-squared test for given probabilities
##
## data: daznis
## X-squared = 35, df = 4, p-value = 4.645e-07
```

Kadangi visos kategorijos lygios, tai tikimybinės lentelės nesudarome. $pv = 4.6453484 \times 10^{-7} < \alpha = 0.05$, todėl hipotezę, kad skirtumai tarp kvadratų $(P(\text{spalva}) - E(P(\text{Hipotezesspalva})))^2$ yra lygūs nuliui, atmetama. Pirkėjai spalvas vertina nevienodai.

- (b) *Hipotezės apie polinominio skirstinio parametrų reikšmes tikrinimas.* (ČM III.5.2) Rinkos analitikas mano, kad A, B, C ir D rūšies pastos vartotojų dalis yra atitinkamai 0.30, 0.60, 0.08, 0.02. Atsitiktinai apklausus 600 žmonių, kokią pastą jie vartoja, gauti rezultatai, kurie pateikiami lentelėje

| Rūšis | A | B | C | D |
|--------|-----|-----|----|----|
| Dažnis | 192 | 342 | 44 | 22 |

Ar šie duomenys leidžia suabejoti rinkos analitiko teiginiu?

$$H : p_1 = p_1^0, p_2 = p_2^0, p_3 = p_3^0, p_4 = p_4^0$$

```
daznis <- c(192, 342, 44, 22)
tikimybės <- c(0.30, 0.60, 0.08, 0.02)

t <- chisq.test(daznis, p=tikimybės) #cia jau turime tikimybės
pv <- t$p.value
t
```

```
##
```

```
## Chi-squared test for given probabilities
##
## data:  daznis
## X-squared = 10.367, df = 3, p-value = 0.01569
```

$p_v = 0.0156932 < \alpha = 0.05$, todėl hipotezę, kad skirtumai tarp kvadratų, yra lygus nuliui, atmetama. Duomenys leidžia teigti, jog analitikas neteisis.

- (c) *Požymių nepriklausomumo tikrinimas*. Lentelėje pateikti skaičiai sutukuotinių, sugrupuotų pagal vaikų skaičių (požymis A) ir metines pajamas (požymis B). Reikia patikrinti hipotezę dėl požymių A ir B nepriklausomumo.

| | 0 – 1 | 1 – 2 | 2 – 3 | 3 | Σ |
|----------|-------|-------|-------|------|----------|
| 0 | 2161 | 3577 | 2184 | 1635 | 9557 |
| 1 | 2755 | 5081 | 2222 | 1052 | 11110 |
| 2 | 936 | 1753 | 640 | 306 | 3635 |
| 3 | 325 | 419 | 96 | 38 | 878 |
| 4 | 39 | 98 | 31 | 14 | 182 |
| Σ | 6216 | 10928 | 5173 | 3046 | 25362 |

```
data <- matrix(
  c(2161, 2755, 936, 325, 39,
    3577, 5081, 1753, 419, 98,
    2184, 2222, 640, 96, 31,
    1635, 1052, 306, 38, 14),
  5,
  4,
  dimnames=list(
    vaiku.sk=c("0", "1", "2", "3", "4"),
    pajamos=c("0-1000", "1000-2000", "2000-3000", "3000+")
  )
)

t <- chisq.test(data)
pv <- t$p.value
t
```

```
##
## Pearson's Chi-squared test
##
## data:  data
## X-squared = 628.27, df = 12, p-value < 2.2e-16
```

$p_v = 9.6787313 \times 10^{-127} < \alpha = 0.05$, todėl hipotezę, kad $P(Vaiku.sk|Pajamos) = P(Vaiku.sk)\dot{P}(Pajamos)$ arba apie požymių priklausomumą, atmetame.

- (d) *Požymių nepriklausomumo tikrinimas* (ČM III.5.4) Buvo tirta, ar užimamos pareigos ir pasitenkinimas darbu yra tarpusavy susiję dalykai. Atsitiktinai apklausus 800 aukštųjų mokyklų dėstytojų, buvo gauti tokie rezultatai:

| | Asistentas | Lektorius | Docentas | Profesorius |
|-----------------|------------|-----------|----------|-------------|
| Patenkintas | 40 | 60 | 52 | 63 |
| Neturi nuomonės | 78 | 87 | 82 | 88 |
| Nepatenkintas | 57 | 63 | 66 | 64 |

Patikrinkite hipotezę apie pareigų ir pasitenkinimo darbu priklausomybę.

```
dnames <- list(
  Pasitenkinimas = c("Patenkintas", "Neturi nuomones", "Nepatenkintas"),
  Pareigos = c("Asistentas", "Lektorius", "Docentas", "Profesorius")
)
Job <- matrix(
  c(40, 78, 57,
    60, 87, 63,
    52, 82, 66,
    63, 88, 64),
  3,
  4,
  dimnames=dnames
)

fisher.test(Job, workspace=2e7)
```

```
##
## Fisher's Exact Test for Count Data
##
## data: Job
## p-value = 0.8383
## alternative hypothesis: two.sided
```

```
chisq.test(Job)
```

```
##
## Pearson's Chi-squared test
##
## data: Job
## X-squared = 2.7506, df = 6, p-value = 0.8394
```

$p_v > \alpha = 0.05$, todėl hipotezės, kad $P(\text{Pareigos} \parallel \text{Pasitenkinimas}) = P(\text{Pareigos})P(\text{Pasitenkinimas})$ arba apie pareigų ir pasitenkinimo darbu priklausomumą negalime atmesti.

- (e) *Homogeniškumo hipotezės tikrinimas*. Viename sraute iš 300 stojančiųjų pažymius “nepatenkinamai”, “patenkinimai”, “gerai” ir “labai gerai” gavo atitinkamai 33, 43, 80 ir 144; kito srauto stojantieji atitinkamai 39, 35, 72, ir 154. Ar galima laikyti, kad abiejų srautų stojantieji pasiruošę vienodai?

```
dnames <- list(
  Ivertinimas = c("Nepatenkinamai", "Patenkinamai", "Gerai", "Labai gerai"),
  Srautas = c("Pirmas", "Antras")
)

rezultatai <- matrix(
  c(33, 43, 80, 144,
    39, 35, 72, 154),
  4,
  2,
  dimnames=dnames
)

fisher.test(rezultatai, workspace=2e7)
```

```
##
## Fisher's Exact Test for Count Data
```

```
##
## data: rezultatai
## p-value = 0.5541
## alternative hypothesis: two.sided
```

```
chisq.test(rezultatai)
```

```
##
## Pearson's Chi-squared test
##
## data: rezultatai
## X-squared = 2.0771, df = 3, p-value = 0.5566
```

$p_v > \alpha = 0.05$, todėl hipotezės, kad $P(Ivertinimas|Srautas = 1) = P(Ivertinimas|Srautas = 1) = P(Ivertinimas)$ arba apie rezultatų priklausymą nuo imties, atmesti negalime.

- (f) *Homogeniškumo hipotezės tikrinimas* (ČM III.5.6) Sveikatos apsaugos ministerija tyrė, ar įvairių profesijų žmonių alkoholio vartojimo įpročiai buvo tokie pat. Atsitiktinai apklausus 200 mokytojų, 300 teisininkų ir 400 gydytojų, buvo gauti tokie rezultatai:

| | Mokytojai | Teisininkai | Gydytojai |
|--------------|-----------|-------------|-----------|
| Mažai | 100 | 50 | 100 |
| Vidutiniškai | 50 | 150 | 200 |
| Daug | 50 | 100 | 200 |

Ar galima teigti, kad šių trijų profesijų atstovų alkoholio vartojimo įpročiai tokie pat?

```
dnames <- list(
  Alkoholis=c("Mazai", "Daug", "Vidutiniskai"),
  Profesija=c("Mokytojas", "Teisininkas", "Daktaras")
)
```

```
sotke <- matrix(
  c(100,50,100, 50,150,200, 50,100,200),
  3,
  3,
  dimnames=dnames
)
```

```
fisher.test(sotke, workspace=2e7)
```

```
##
## Fisher's Exact Test for Count Data
##
## data: sotke
## p-value < 2.2e-16
## alternative hypothesis: two.sided
```

```
chisq.test(sotke)
```

```
##
## Pearson's Chi-squared test
##
## data: sotke
## X-squared = 91.607, df = 4, p-value < 2.2e-16
```

Abiems kriterijams $pv < \alpha = 0.05$, todėl hipotezę, kad (tikimybės analogiškai kaip praėjusiam pavyzdy) arba rezultatų priklausymą nuo imties, atmetame.

Padaryta su R version 3.4.2 (2017-09-28), x86_64-pc-linux-gnu.